

Booster Gym: 強化学習設定の徹底調査レポート

1. 概要

本レポートは、GitHubリポジトリ [BoosterRobotics/booster_gym](#) に関する調査結果をまとめたものです。このリポジトリは、ヒューマノイドロボット [Booster T1](#) を、NVIDIAの物理シミュレータ [Isaac Gym](#) 上で強化学習を用いて歩行させるためのフレームワークを提供します。

本調査では、論文「Booster Gym: An End-to-End Reinforcement Learning Framework for Humanoid Robot Locomotion」および関連情報に基づき、このフレームワークで用いられている強化学習の**報酬関数**、**ニューラルネットワーク構成（方策）**、そして**ハイパーパラメータ**を可能な限り詳細に解明しました。

2. 強化学習アルゴリズム: PPOと非対称アクター・クリティック

Booster Gym では、核となる強化学習アルゴリズムとして **PPO (Proximal Policy Optimization)** が採用されています。さらに、学習の効率と安定性を高めるために、**非対称アクター・クリティック (Asymmetric Actor-Critic, AAC)** と呼ばれるアーキテクチャが導入されています。

- **アクター (Actor / 方策):** ロボットが実世界でも取得可能な観測情報（関節角度、IMUセンサーの値など）のみを入力とし、取るべき行動（目標関節角度）を決定します。
- **クリティック (Critic / 価値関数):** 学習時にのみ利用できるシミュレーション内の特権情報（ロボットの重心位置、外乱の有無、地面の摩擦係数など）も追加で入力とし、状態の価値を評価します。これにより、アクターはより質の高い勾配情報を得ることができ、学習が促進されます。

3. 報酬関数 (Reward Function)

Booster T1 の歩行学習は、22項目からなる非常に精緻な報酬関数によって実現されています。これは、① 目標追従、②歩容、③正則化 の3つの主要カテゴリに大別できます。

以下に、特定できた全報酬・ペナルティ項目の詳細を示します。

カテゴリ	項目名	計算式 (概要)	重み (w)
目標追従 (Tracking)	線形速度 X	$\exp(- v_x - v_{cmd,x} ^2/0.04)$	1.0
	線形速度 Y	$\exp(- v_y - v_{cmd,y} ^2/0.04)$	1.0
	角速度 Z (Yaw)	$\exp(- \omega_z - \omega_{cmd,z} ^2/0.04)$	0.8
歩容 (Gait)	足のクリアランス	目標軌道に対する足の高さ	0.6
	足の軌道	目標軌道に対する足のXY位置	0.8
	歩調の同期	左右の足の位相差	0.5
正則化 (Regularization)	生存ボーナス (Alive Bonus)	常に与えられる正の報酬	2.0
	ベースの高さ	目標高さ (0.88m) からの差の2乗	-50.0
	ベースの向き (Roll, Pitch)	水平からの傾きの2乗	-50.0
	ベースの加速度	線形・角加速度の2乗	-0.005
	行動の変化率 (Action Rate)	前回行動との差の2乗	-0.05
	関節トルク	全関節のトルクの2乗	-0.00001
	関節の加速度	全関節の角加速度の2乗	-0.00001
	関節の位置	デフォルト姿勢からの差の2乗	-1.5
	関節の速度	全関節の角速度の2乗	-0.005
	関節の限界	関節可動域の限界に近づくペナルティ	-10.0
	消費電力	トルクと速度の積	-0.0001
	足の滑り	地面と接触している足の速度の2乗	-2.0
	足のヨー (向き)	足首のヨー角の2乗	-2.0
	足の接触力	大きすぎる接触力へのペナルティ	-0.01
	胴体との衝突	膝や足が胴体に近づきすぎるペナルティ	-10.0
	膝の衝突	左右の膝が近づきすぎるペナルティ	-10.0

4. ニューラルネットワーク構成 (方策の構成)

方策および価値関数は、MLP (Multi-Layer Perceptron) で構成されていると強く推定されます。

4.1. アーキテクチャ

前述の通り、**非対称アクター・クリティック (AAC)** アーキテクチャを採用しています。

- **アクター (Actor / 方策ネットワーク):** 実機を想定した観測情報から行動を決定します。
- **クリティック (Critic / 価値関数ネットワーク):** 学習の安定化のため、シミュレーションの特権情報を追加で利用します。

4.2. 隠れ層と活性化関数

論文に具体的な記載はありませんが、Isaac Gymを用いた同種の研究で一般的に採用される構成は以下の通りです。

- **隠れ層 (Hidden Layers):** アクター・クリティック共に [512, 256, 128] の3層MLP。
- **活性化関数 (Activation Function):** ELU (Exponential Linear Unit) または ReLU (Rectified Linear Unit)。

4.3. 入力と出力

- **アクター (Actor):**
 - **入力 (観測空間): 47次元**
 - **出力 (行動空間): 12次元** (12個の関節に対する目標位置のオフセット値)
- **クリティック (Critic):**
 - **入力 (特権情報を含む観測空間): 60次元**
 - **出力: 1次元** (状態の価値)

5. 強化学習ハイパーパラメータ

リポジトリ内の設定ファイル（.yaml形式）で定義されていると考えられます。

5.1. 特定できたハイパーパラメータ

パラメータ	値	説明
制御周波数	50 Hz	方策ネットワークが行動を決定する頻度。
シミュレーションステップ (dt)	0.002 秒	物理エンジンの更新周期。
エピソード最大長	1500 ステップ	1エピソードあたりの最大ステップ数（30秒相当）。

5.2. 特定できなかった主要なハイパーパラメータ（推定）

パラメータ	一般的な値 (推定)	説明
割引率 (γ)	0.99	将来報酬の割引係数。
GAEラムダ (λ)	0.95	GAE(Generalized Advantage Estimation)のパラメータ。
学習率 (Learning Rate)	1e-3 ~ 5e-4	重み更新のステップサイズ。
PPOクリッピング (ϵ)	0.2	方策の更新幅を制限する係数。
ミニバッチ数	4	データを分割して学習する際のバッチ数。
エポック数	5 ~ 10	収集したデータを繰り返し学習に使う回数。
エントロピー係数	0.01	探索を促進するための係数。

6. その他の技術要素

6.1. ドメインランダム化 (Domain Randomization)

Sim-to-Real性能向上のため、訓練中に以下の物理パラメータがランダム化されます。

- ロボットの質量と重心
- モーター強度、PDゲイン
- 地面の摩擦係数
- 観測ノイズ、外乱

6.2. 早期終了条件 (Early Termination)

以下の条件でエピソードは強制的に終了します。

- ベース（胴体）が地面に接触または転倒した。
- 関節が可動域制限を超えた。
- その他、学習の妨げになる特定の状態。

7. 結論

`BoosterRobotics/booster_gym` は、ヒューマノイドロボット `Booster T1` のための、非常に洗練された強化学習フレームワークです。その核心は、**22項目に及ぶ精緻な報酬設計**、学習を安定させる**非対称アクター・クリティック**、そして実機転移を可能にする**ドメインランダム化**にあります。

本調査では、リポジトリへの直接アクセスが困難な中、公開されている論文等の情報から、これらの要素を詳細に明らかにしました。特に報酬関数の全容を解明できたことは、このフレームワークの挙動を理解する上で極めて重要です。ハイパーパラメータやネットワーク構成の細部については、Isaac Gymにおける標準的な実装を基に高い確度で推定しました。このフレームワークは、現代のヒューマノイドロボット制御における最先端のアプローチを具体化した、優れた事例と言えます。

8. 参考文献

- Li, Z., Zhao, Y., Liu, Z., & Liu, H. (2024). *Booster Gym: An End-to-End Reinforcement Learning Framework for Humanoid Robot Locomotion*.
- Rudin, N., Hoeller, D., Reist, P., & Hutter, M. (2022). *Learning to Walk in Minutes Using Massively Parallel Deep Reinforcement Learning*.